第一章 数据挖掘与人工智能概述

1.1 数据挖掘

必要性 **数据爆炸问题**：自动收集技术获取了巨量的数据，但缺乏有用的信息，无法发现数据中存在的**关系**和**规则**，无法根据现有的数据**预测**未来的发展**趋势**。

经典案例：购物篮案例
挖掘目标：关联规则（牛奶→鸡蛋（支持度 2%，置信度 60%））。 支持度：分析中的全部事务的 2%同时购买了牛奶和鸡蛋。 置信度：购买了牛奶的顾客有 60%也购买了鸡蛋。

数据挖掘 ***Data Mining***，从**大量的数据**中提取隐含在其中的、人们事先不知道的、但又潜在有用的**信息**和**知识**的过程，同义词 **KDD**。其可以从异常复杂的数据中发现规律。

应用领域 超市业务、客户与市场分析、电子商务、推荐系统、金融证券、社交网络分析、网络舆情安全等。

技术关系
① **模式识别 PR** 奠定了机器学习最重要的**理论模型**。
② **深度学习 DL** 是机器学习中发展最快的**研究热点**。
③ **统计分析**与**机器学习**为数据挖掘提供了方法的**支撑**。
④ **数据挖掘**更多聚焦于**应用问题**的解决。

问题导向
① **回归**：**预测性**问题，传统模式识别。（例如线性、逻辑、多项式、逐步、岭回归）
② **分类**：**预测性**问题，**有监督**（有标签），机器学习。
③ **聚类**：**描述性**问题，**无监督**（无标签），数据挖掘。
④ **关联规则**、**序列模式**、**异常点检测**：数据挖掘。

2 人工智能概述

2.1 什么是人工智能

人工智能 让机器**模拟人类智能行为**的技术和科学。旨在让计算机能够执行通常**需要人类智能**的任务，比如**学习、推理、解决问题、理解语言**和**感知环境**等。方向有计算机视觉、智能语音、自然语言处理、深度学习基本四要素为**算力、算法、数据、场景**（产学研用）。

图灵测试
5 分钟内回答询问者的一系列问题，如果 30%的询问者认为对方为人类，则通过图灵测试。

数据 **数据是人工智能的基础**，机器学习需要**大量的数据**进行训练和优化。
数据的**质量、数量**和**多样性**，对人工智能的性能和准确性至关重要。
需要收集整合各种来源的数据进行预处理和清洗，确保数据的准确性和一致性。

算力 计算机的处理能力，包括 **CPU\GPU\TPU** 等硬件设备。

TPU 张量处理单元
Tensor Processing Unit，也称张量处理器，是 Google 开发的专用集成电路（ASIC），专门用于加速机器学习。

算法 人工智能的**核心**，它指导计算机如何处理和分析数据的指令。

场景 人工智能应用的具体环境和使用场景。

类型 ① **弱人工智能**：**ANI** ***narrow***，**专用人工智能**，专注于且只能解决特定领域问题的人工智能。
② **强人工智能**：**AGI**，***general***，也称为**通用人工智能**，能够胜任人类所有的智力型工作。
③ 超人工智能：**ASI**，***super***，在几乎所有领域都具有比人类更强的性能。

2.2 人工智能的发展

早期探索 **1956 年以前**：数理逻辑、神经元 1943、ENIAC 的诞生 1946
形成与发展 **1956-1970**：**达特茅斯会议** 1956、LISP 1958、工业机器人 1959、通用问题求解程序 GPS 1960 等
低谷与突破 **1970-1990**：**专家系统**、聊天机器人等
复兴与繁荣 **1990-至今**：IBM 深蓝 1997、**GPT** 2020
第一次浪潮 **算法缺陷**：基于数学模型和数学手段有一定的缺陷。
性能不足：计算复杂度以指数程度增加。
缺乏常识：逻辑证明器、感知器、增强学习等只能处理非常简单、非常专门且狭窄的任务。
第二次浪潮 缺乏真实的应用场景，BP 神经网络缺少严格的数学理论支持。
第三次浪潮 **认知智能浪潮**，需要大量数据、算法、算力的支持。

2.3 人工智能的关键技术

关键技术 **机器学习**和**深度学习**。
机器学习 通过对**大量的数据**的分析，**自动识别**数据中的**模式**，并利用这些模式进行**预测或决策**。与传统方法中人为定义的规则不同，机器学习让计算机从数据中归纳规则。
分为**监督学习**（有标签）、**无监督学习**（无标签）、**强化学习**（评级标签）。
常用算法 ① **线性回归**：模拟一条分类线，进行二分类。
② **逻辑回归** ③ **决策树** ④ **朴素贝叶斯** ⑤ **支持向量机 SVM**
⑥ **集成学习** ⑦ **K 近邻算法** ⑧ **K-means 算法** ⑨ **神经网络**
三个阶段 传统机器学习模型→深度学习模型→超大规模深度学习模型
深度学习 基于人工神经网络发展而来，通过构建深层次的网络结构，自动从大量数据中学习到复杂、抽象的特征表示。
计算机视觉 ***Computer Version***，使用计算机和相关设备对**生物视觉**进行模拟的一种技术。
NLP **自然语言处理** ***Natural Language Processing***，让计算机能够理解、处理和生成人类使用的**自然语言**、实现人类与计算机之间的自然交互。其包括**自然语言理解 NLU** 和**自然语言生成 NLG**。

具体技术
NLP：词汇表示和分析、短语表示和分析、句法语义表示分析、篇章表示词汇分析。 NLP：机器翻译、问答聊天、知识库、机器翻译、情感分析、文本生成等。 基本技术：用户画像、大数据、云计算、机器学习、深度学习、领域知识。

语音识别 把人说的话变成机器能够理解的文字信息。
智能语音 融合**语音识别、语音合成、自然语言**处理等技术，实现人类与机器之间流畅的语音交互。
AIGC **生成式人工智能 Artificial Intelligence Generated Content**。赋予机器全新创造内容的能力，涵盖图像、文本、音频、视频等多种形式，具有一定的原创性和合理性。
知识图谱 一种用于表示、存储和查询复杂知识网络的**数据结构**。通过图形化的方式展示实体和实体之间的关系。
专家系统 将特定领域专家的**专业知识和经验**进行整理、编码，让计算机能够模拟专家的思维方式，解决该领域的复杂问题。