第一章 数据挖掘概述

1.1 数据挖掘

必要性 **数据爆炸问题**：自动收集技术获取了巨量的数据，但缺乏有用的信息，无法发现数据中存在的**关系**和**规则**，无法根据现有的数据**预测**未来的发展**趋势**。

经典案例：购物篮案例
挖掘目标：关联规则（牛奶→鸡蛋（支持度 2%，置信度 60%））。 支持度：分析中的全部事务的 2%同时购买了牛奶和鸡蛋。 置信度：购买了牛奶的顾客有 60%也购买了鸡蛋。

数据挖掘 ***Data Mining***，从**大量的数据**中提取隐含在其中的、人们事先不知道的、但又潜在有用的**信息**和**知识**的过程，同义词 **KDD**。其可以从异常复杂的数据中发现规律。

应用领域 超市业务、客户与市场分析、电子商务、推荐系统、金融证券、社交网络分析、网络舆情安全等。

技术关系
① **模式识别 PR** 奠定了机器学习最重要的**理论模型**。
② **深度学习 DL** 是机器学习中发展最快的**研究热点**。
③ **统计分析**与**机器学习**为数据挖掘提供了方法的**支撑**。
④ **数据挖掘**更多聚焦于**应用问题**的解决。

问题导向
① **回归**：**预测性**问题，传统模式识别。（例如线性、逻辑、多项式、逐步、岭回归）
② **分类**：**预测性**问题，**有监督**（有标签），机器学习。
③ **聚类**：**描述性**问题，**无监督**（无标签），数据挖掘。
④ **关联规则**、**序列模式**、**异常点检测**：数据挖掘。