第二章 深度学习

2.1 机器学习概念

聚类 让数据**自然分组**的方法，把相似的数据自动归为一组，让同一组的数据长得像，不同组的数据差别大。一般需要提前指定分组类别数量。

降维 将复杂的数据瘦身，从**高维**（大量特征）**变成低维**（少量关键特征），同时保留有主要信息。

> 案例
>
> 输入多维数据（身高、体重、腰围、体脂率等）→降维模型→低维数据（体型指数）

异常检测 找到数据中格格不入的样本，这些样本与其他数据**差异过大**。例如诈骗检测。

监督学习 目标明确、训练数据被标记、效果容易评估、分类与回归。

无监督学习 目标不明确、训练数据未被标记、效果难以评估、聚类、降维或异常检测。

强化学习 智能体与环境进行交互，根据环境反馈的奖励信号来学习最优策略。没有标准答案，但是有评估标准，来不断地奖励或者批评模型，帮助其实现最优解。

2.2 常用算法

常用算法 线性回归、逻辑回归、聚类算法、**决策树、支持向量机**、人工神经网络、随机森林、深度学习等。

线性回归 建立**因变量**和**一个或多个自变量**之间的**线性关系**。其计算简单高效，容易理解和解释，但对**异常值**较**敏感**，只能捕捉到**线性联系**。

逻辑回归 通过拟合一个**逻辑函数**，将输入特征的线性组合映射到[0,1]的概率区间，用于处理**二分类任务**。其简单易懂，计算效率高，能供直观地解释预测结果，但很难处理复杂的非线性分类问题。

聚类算法 分析数据之间的相似度，把相似的数据分到一个组别，每组叫做一个**"簇"**。这是一种无监督学习方法。无需标签，可以灵活地发现各种模式，但需要预先指定**簇的数量**，对初始簇中心的选择非常敏感，可能导致结果不稳定。

决策树 基于**树结构**的分类和回归算法，通过对数据的特征进行测试，根据测试结果将数据划分到不同的分支。简单易懂、灵活通用、可快速预测；但容易过拟合、稳定性差、不适合处理复杂问题。

随机森林 **SVM**，由**多个决策树**组成的集合学习模型，从原始训练数据随机又放回地抽取多个子集，分别训练决策树，然后综合这些决策树的结果（平均/投票）进行预测，以提高模型的稳定性和准确性。
其准确率较高、可并行训练、解释性较好、抗噪声能力强；但训练速度较慢、模型较大、对超参敏感。

支持向量机 一种监督学习算法，核心思想是找到一个**最优的决策边界**（超平面），将不同的数据分开，并且使得这个边界到最近数据点的**距离**（间隔）**最大化**。
其分类校准、适合小数据量；但是训练时间长，不适合大模型。

神经网络 **ANN**，由一个**输入层+隐藏层+输出层**实现。

深度学习 **DL**，使用**多层神经网络**来自动学习和提取数据的多层次特征。

> 深度学习将特征提取和分类合二为一，是一种端到端的学习方法。